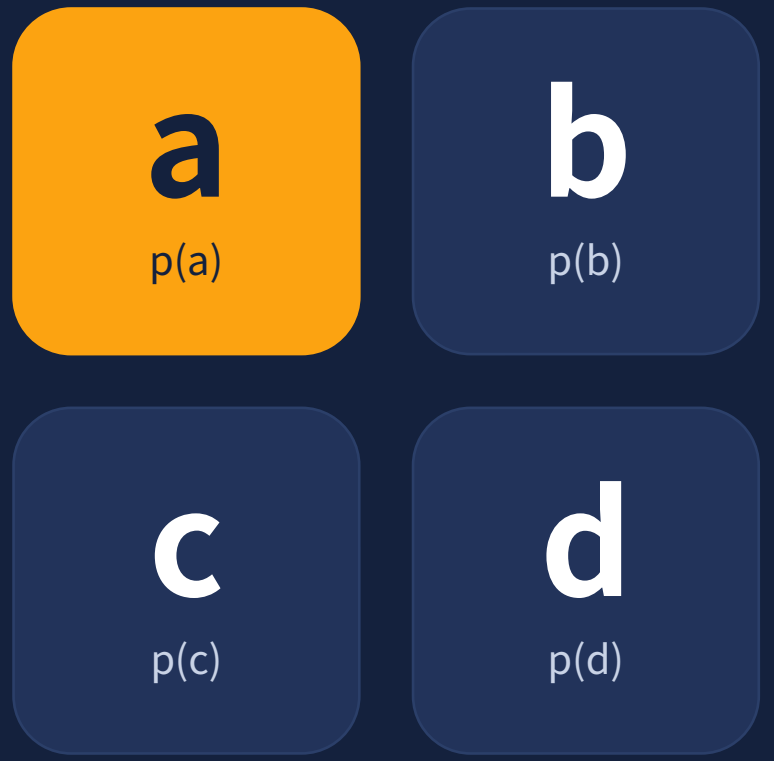
SSAFY 16 기 2 회차 AI 챌린지 · 텍스트 이미지 기반 VQA

여러 VLM 의 a~d 확률을 검증으로 묶다

이미지 속 글자를 읽는 4 지선다 VQA 솔루션 설명
접근 전략 · 데이터 처리 · 모델 개발 · 실험 설계 · 실행 방법



답 자리 토큰의 a~d 확률로 답을 고릅니다

A084_ 성훈 있는 성훈팀

2026-09-28

한눈에 보기

여러 VLM 을 같은 조건으로 학습 · 채점하고 , 검증 1,000 문항만으로 조합을 골랐습니다 .

검증 정확도

98.0%

최종 조합 · 고정 검증 1,000 문항

공개 리더보드

0.97736

최고 점수 · 3,281 / 3,357 문항

학습 규모

20 개

LoRA 실행 · 기반 모델 10 종 (7 계열)

1 같은 조건으로 비교

고정 검증 분할 · 같은 프롬프트 · 답 자리 a~d 확률 채점으로 모든 모델을 같은 문항에서 직접 비교했습니다 .

2 다양한 모델 확보

VLM 10 종을 LoRA 로 파인튜닝하고 , 학습 없는 대형 모델 (Qwen3.5-122B GPTQ 등) 까지 모든 확률을 저장했습니다 .

3 검증으로만 조합 선택

확률 평균 조합을 검증 1,000 문항으로 고르고 , 고르는 과정의 부풀림은 중첩 교차검증으로 따로 쟀습니다 .

과제와 데이터

이미지 속 글자를 읽고 네 보기 중 정답 하나를 고르는 과제 — 평가 지표는 정확도

예시 이미지 자리

대회 데이터라
공개본에는 넣지 않았습니다

train 예시 이미지 (원본은 대회 데이터)

Q. 사진 속 선반에 적힌 문구는 무엇인가요 ?

- **a** **SUNDAY BURGER LOVE**
- **b** MONDAY SALAD TIME
- **c** FRIDAY PIZZA PARTY
- **d** WEDNESDAY SOUP DAY

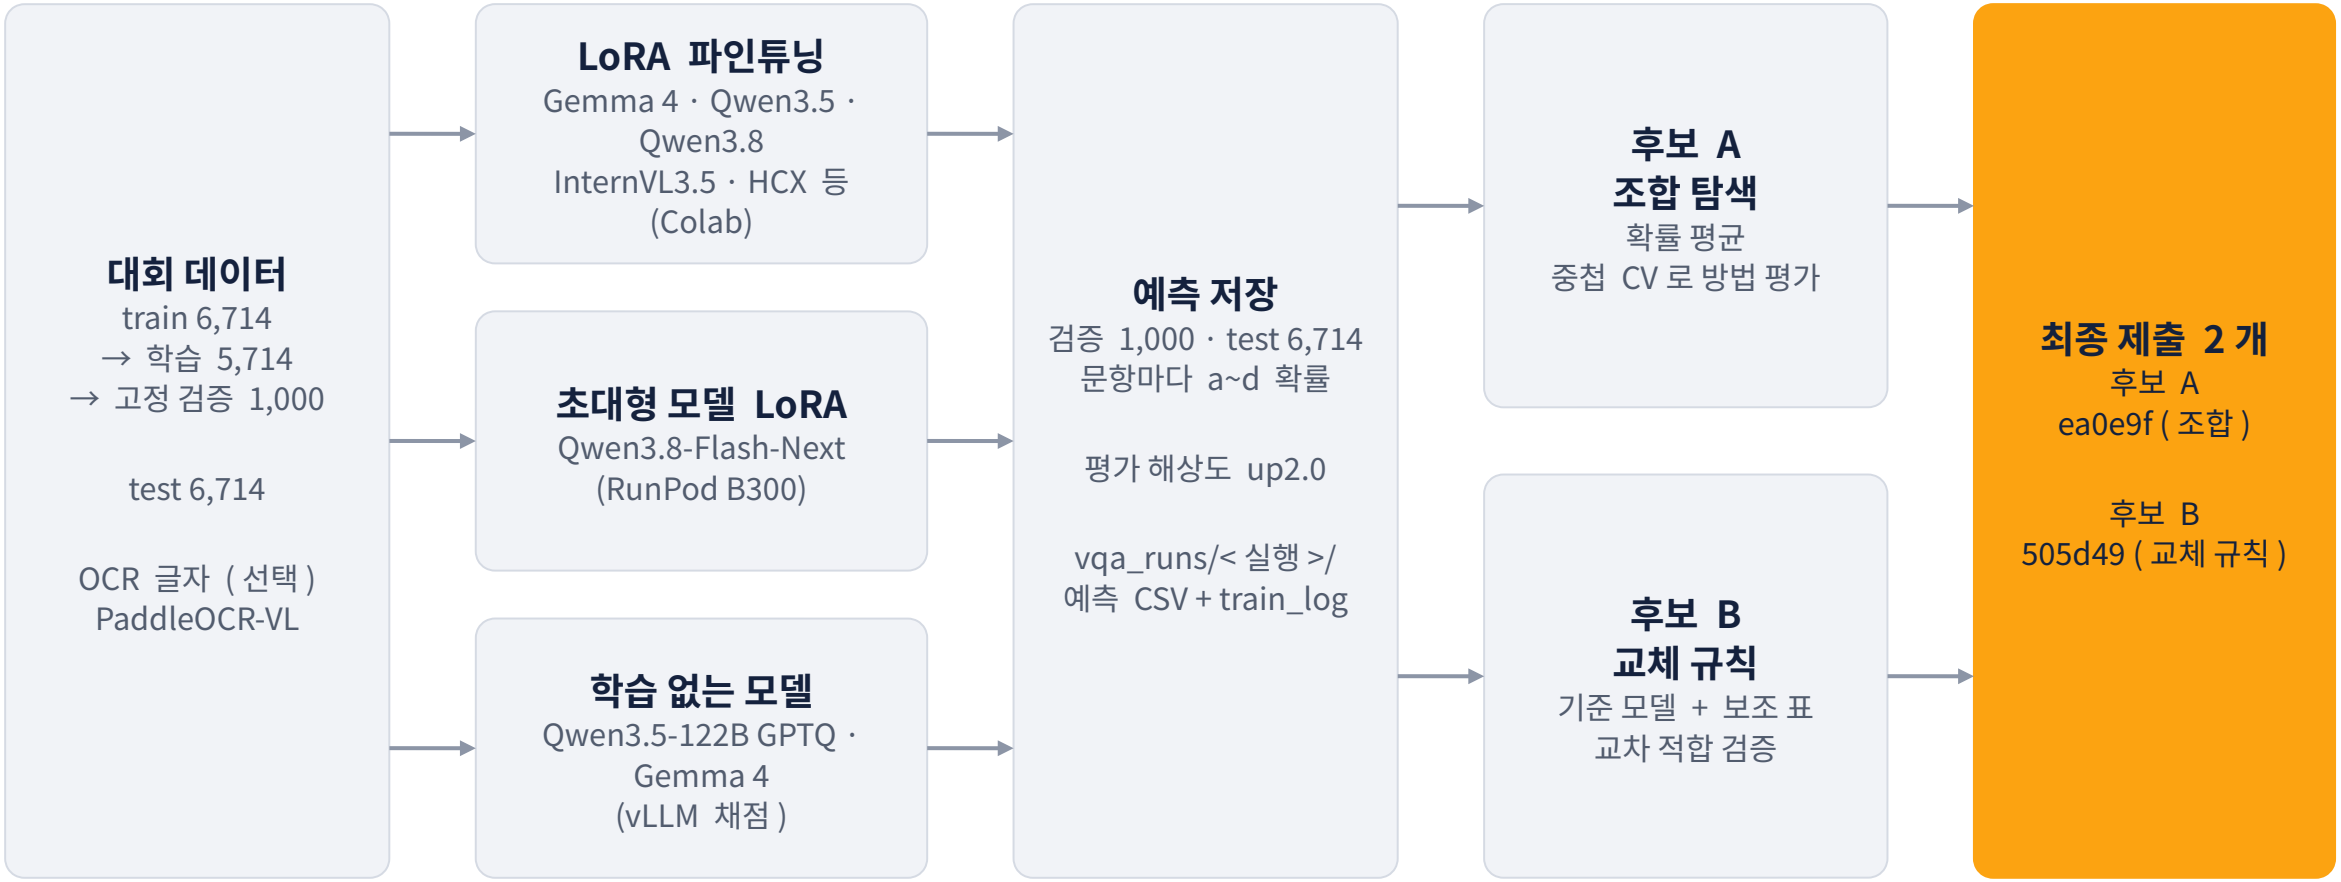
정답 : a

데이터	문항	쓰임
train – 검증	5,714	LoRA 학습
고정 검증	1,000	모델 비교 · 조합 선택
test	6,714	추론만 (공개 점수는 3,357 문항)
dev	2,683	정답 없음 → 조건부 의사 라벨

- 사진은 대부분 720×960
- 외부 데이터는 쓰지 않음
- train 6,714 = 학습 5,714 + 검증 1,000

접근 전략 — 전체 파이프라인

모든 모델이 같은 형식 (문항별 a~d 확률) 으로 예측을 남기고 , 조합 단계에서 합칩니다 .



실험 설계 — 무엇이 진짜 개선인지 가리기

검증이 1,000 문항 (오답 20 여 개) 이라 ±3 문항은 우연 범위 — 판정 절차부터 정했습니다 .

1 고정 검증 1,000 문항

train 에서 정답 글자별 250 문항씩 뽑음 (시드 42). 모든 노트북이 분할 md5 를 확인하고 , 다르면 멈춥니다 .

글자별 250 × 4 = 1,000 문항 · 분할 md5 df05e4bc...

2 같은 문항 비교

정확도 한 숫자 대신 고친 문항 · 새로 틀린 문항 · 순이득으로 판정하고 부호 검정을 봅니다 .

예 : Qwen3.5 학습 전 → 후 고침 13 · 새로 틀림 2 → 순이득 +11

3 규칙은 결과 전에

채택 기준을 실행 전에 적어 둡니다 . 예 : 앙상블 순이득 ⩾ +3 이고 새로 틀린 문항 ⩽ 고친 문항의 절반 .

예 : 학습 변형 19 가지 → 모두 기준 미달로 불채택

4 고르는 과정도 평가

조합 · 문턱값 선택은 중첩 교차검증 · 교차 적합으로 재고 , 공개 리더보드는 확인용으로만 씁니다 .

예 : 검증 1 등 조합 98.0% → 같은 방법의 중첩 CV 97.53%

데이터 처리

대회 데이터만 사용 — 해상도 , 보기 섞기 , 보조 · 의사 라벨 , OCR, 라벨 점검

1 이미지 · 해상도

EXIF 방향 보정 · RGB. 평가 ·test 는 up2.0(약 2 배): Qwen·HCX 270 만 ~340 만 픽셀 , Gemma 4 소프트 토큰 1,120 개 , InternVL 타일 12 개 .

2 증강

epoch 마다 보기 순서를 섞고 정답 글자도 함께 바꿈 (자리 편향 제거). 글자 과제라 회전 · 반전 · 자르기는 쓰지 않음 .

3 보조 학습 데이터

보기 없이도 답이 정해지는 글자 읽기 문항 (가격 · 시간 · 전화 · 상호 · 층 · 문구) 만 골라 단답형 목표로 사용 .

4 dev 의사 라벨

교육생 응답은 4~5 명 일치가 0 문항 (최다 3 표). 모델 확신 ⩾ 0.8 이고 3 표 이상 다수결과 같은 문항만 사용 .

5 OCR (선택)

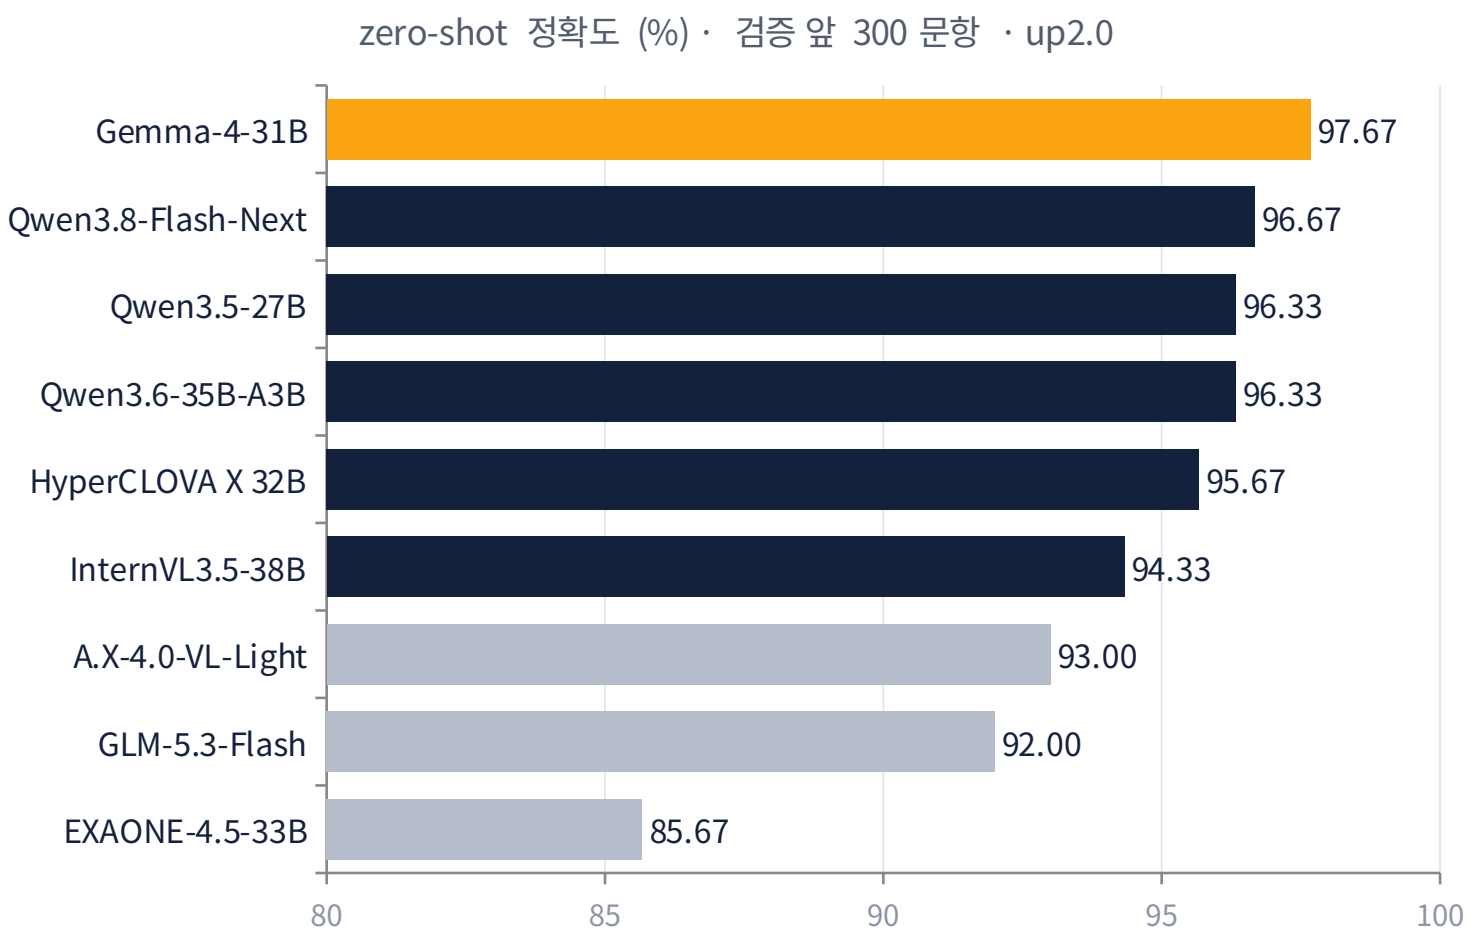
PaddleOCR-VL 로 글자 줄 · 위치 추출 . 반복 루프는 정리하고 , 1,000 자를 넘으면 질문 · 보기와 겹치는 줄부터 남김 .

6 라벨 점검

검증 오답을 이미지로 직접 확인 : 라벨 오류 약 10 · 답이 둘 다 되는 문항 약 8. 학습 라벨은 원본 그대로 사용 .

기반 모델 고르기 — 학습 전에 먼저 재기

검증 앞 300 문항 zero-shot 으로 한국어 글자 읽기를 비교하고 , 약한 모델은 학습하지 않았습니다 .



학습한 모델

학습하지 않음 (글자 읽기 약함)

zero-shot 1 위

학습 후 대략 +1.1~1.4%p

예 : Qwen3.5-27B 96.1 → 97.2 (같은 1,000 문항)

크기보다 계열

320B GLM-5.3-Flash 92.0 · 122B zero-shot 96.0(1,000 문항) < Gemma 4 31B

형식부터 확인

Muse-Glimmer-30B 는 답 자리 형식이 달라 측정 무효 (letter_mass 0.003)

모델 학습 — 하나의 레시피 , 여러 모델

통합 노트북 01_train_vlm 에 실행 이름 (RECIPE) 만 넣으면 train_log 와 같은 설정으로 재현됩니다 .

항목	설정
학습 목표	추론과 똑같은 프롬프트의 마지막 위치 (답 자리) 로짓에만 교차 엔트로피 · 목표는 정답 소문자 한 글자
LoRA	r 16 · α 32 · dropout 0.05 · 언어 모델의 어텐션 ·MLP 선형층 . 선택으로 비전 블록 · 투영층도 (LR × 0.2)
최적화	AdamW · LR 1e-4(이어학습 2e-5) · cosine + warmup 5% · 유효 배치 16 · 1 epoch (8B·9B 는 2 epoch 중 검증으로 선택)
정밀도	20B 이상은 4bit NF4(QLoRA) 또는 bf16. 비전 타워 · 투영층 ·lm_head 는 양자화하지 않음
학습 해상도	native (Gemma 4 31B 만 up2.0 이 더 좋아 up2.0)
이어하기	50 스텝마다 어댑터 · 옵티마이저 · 난수 상태 저장 → 끊긴 곳부터 같은 결과로 이어 학습

답 자리 한 곳만 학습

이미지

질문

(a)~(d) 보기

“ 한 글자로 답”

↓

답 자리 → 정답 글자 1 개

학습 뒤 letter_mass(답 자리의 a~d 확률 합) 가 모든 모델에서 1.000

모델별 처리 — 답 자리와 하드웨어 맞추기

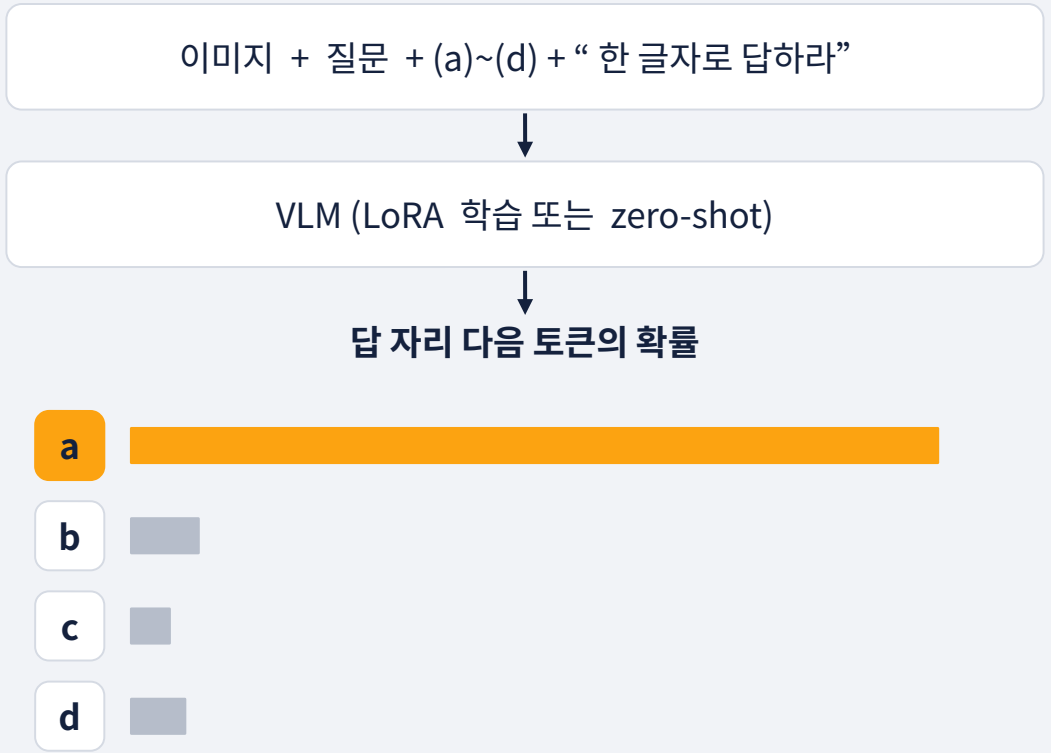
템플릿 · 해상도 단위 · 커널이 모델마다 달라 , 같은 채점을 하려면 개별 보정이 필요했습니다 .

HCX	**HyperCLOVA X SEED Think 32B**	그대로 두면 답 자리에서 생각 블록을 시작 → thinking=False 를 넘기고 열린 <think> 를 </think> 로 닫아 다음 토큰이 곧 답 글자가 되게 함 (transformers 개발 버전 커밋)
해상도	**Gemma 4 · InternVL3.5 · Qwen3.5**	해상도 단위가 다름 : 이미지당 소프트 토큰 수 / 448px 타일 수 / 픽셀 범위 . Qwen3.5 이후는 선형 어텐션 커널 (flash-linear-attention) 을 설치해야 OOM 이 나지 않음
B300	**Qwen3.8-Flash-Next (bf16 330GiB)**	패딩 자리의 전부 가려진 어텐션 행 때문에 역전파가 NaN → 학습 중에만 풀어 넘김 · 희소 어텐션 토큰 선택 벡터화 · 95GiB n-gram 표는 CPU RAM 에
vLLM	**학습 없는 대형 모델 (vLLM 0.30)**	Qwen3.5-122B 는 사전 양자화 GPTQ-Int4 로 G4 96GB 한 장에서 · B300 에서는 즉석 컴파일이 안 돼 Triton 어텐션 ·MoE 커널 사용

보정마다 작은 모델로 원래 구현과 결과 (로짓 · 손실 · 기울기) 가 같은지 대조한 뒤 썼습니다 .

추론 — 생성하지 않고 답 자리 확률로

모든 모델이 문항마다 a~d 네 확률을 남기고 , 이 확률이 조합의 재료가 됩니다 .



대소문자 · 앞 공백 변형 (a, A, “ a”, “ A”) 확률을 합쳐 네 보기로 정규화 · letter_mass(네 글자 확률 합) 로 답 자리 점검

해상도

검증 ·test 모두 up2.0. 보기 순열 4 가지 평균 (TTA) 과 애매한 문항 고해상도 (3·4 배) 재채점은 이득이 없어 쓰지 않음 .

학습 없는 대형 모델 (vLLM)

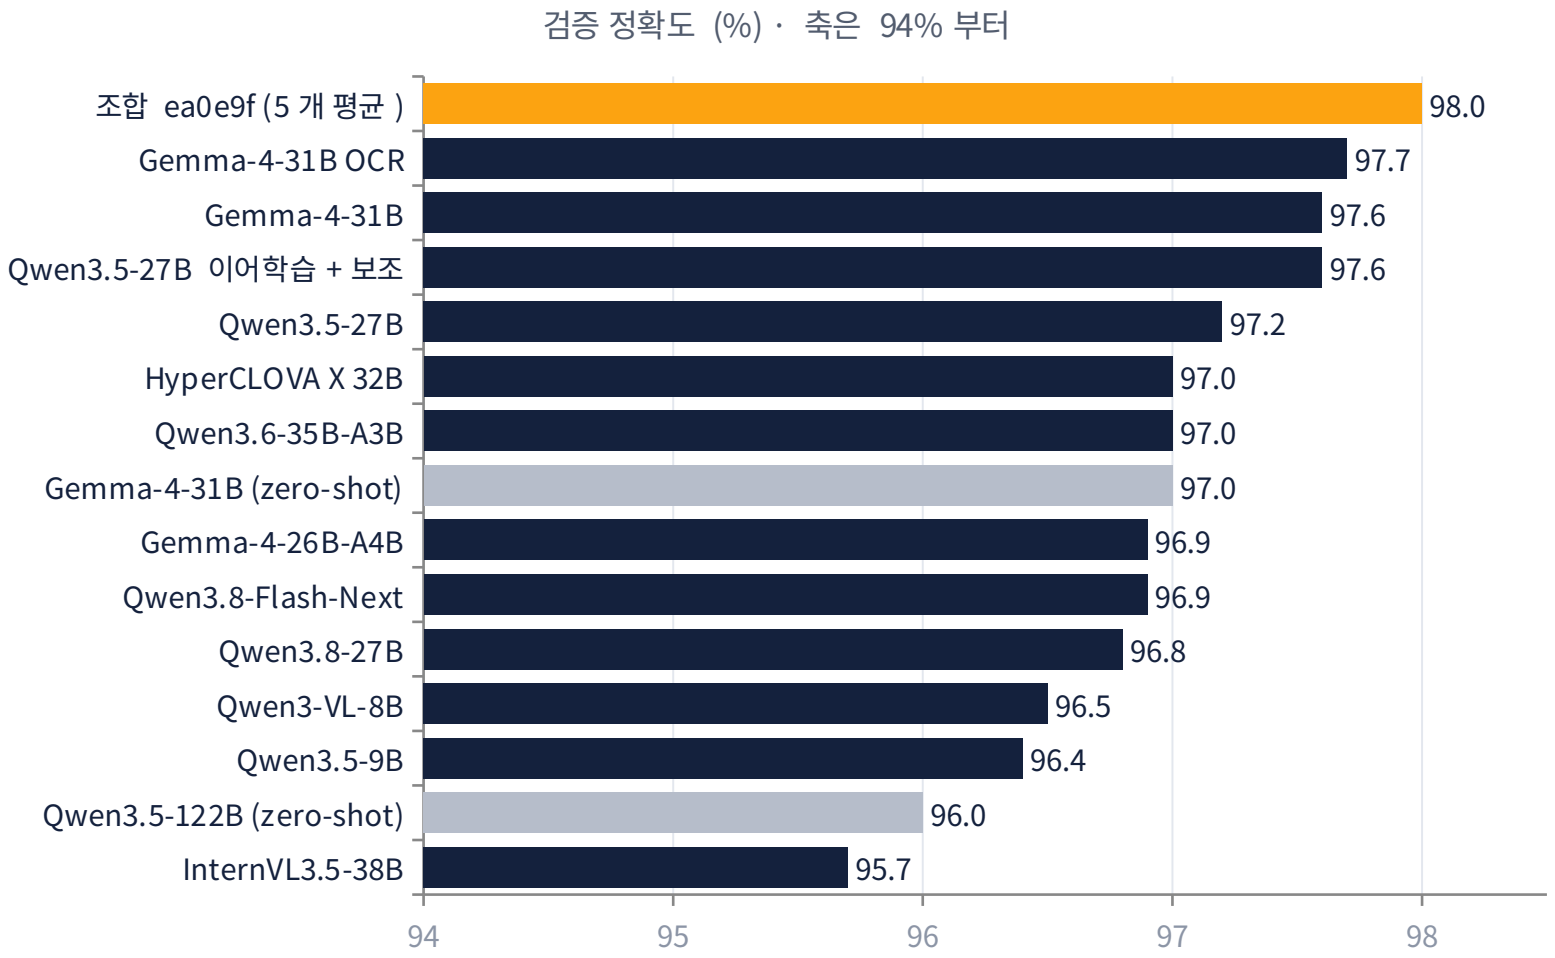
답 자리 상위 64 개 로그확률에서 a~d 수집 . 이미지 크기를 transformers 전처리와 맞춤 . 검증 122B GPTQ 96.0% · Gemma 4 97.0%.

판정 모델 (교차 검증)

기준 · 보조 모델의 답이 갈린 문항만 . 두 답을 모델 A/B 로 제시하고 단계별 결론 → 표본 5 개 다수결이 한 표 , 부족 · 동점은 기권 .

실험 결과 — 단독 95.7~97.7%, 조합 98.0%

고정 검증 1,000 문항 · up2.0. 실행 5 개 (4 계열) 의 같은 가중치 확률 평균이 가장 높았습니다 .



LoRA 학습 모델

zero-shot (학습 없음)

확률 평균 조합

조합 멤버
Gemma 4 bf16 · Gemma 4 OCR · InternVL3.5 · Qwen3.5 bf16 · Qwen3.8

단독 최하위도 조합에
InternVL(95.7) 은 틀리는 문항이 달라 조합에 보탬

정밀도는 병목 아님
같은 시드 NF4·bf16 답 99% 동일 (Qwen3.5 97.2 / 97.1)

후보 A — 검증으로 조합 고르기

결합 3 가지 × 검색 3 가지로 조합을 찾고 , 고르는 과정의 과적합은 중첩 교차검증으로 따로 쟀습니다 .

1 멤버

고정 분할로 학습하고 검증 ·test 예측이 모두 있는 실행 .
검증을 학습에 쓴 _full · 검증 99% 초과 실행은 제외

2 결합

확률 평균 / 멤버별 온도 보정 후 평균 / 로그확률 평균 (
온도는 검증 NLL 최소)

3 검색

같은 가중치 부분집합 전수 (설정마다 약 70 만 조합) ·
그리디 · 좌표 상승

4 평가

중첩 CV 5 겹 × 4 번 : 800 문항으로 검색하고 남은 200
문항으로 채점

98.0% → **97.53%**

검증 1,000 문항에서
고른 최고 조합

같은 방법의
중첩 CV 정확도

→ 1,000 문항에서 고른 최고값은 약 0.5%p 부풀려짐

최종 제출 ea0e9f — 같은 가중치 확률 평균

Gemma 4 bf16 | Gemma 4 OCR | InternVL3.5 | Qwen3.5 bf16 | Qwen3.8

검증 98.0% · 공개 0.97736 (3,281 / 3,357) · 실행 5 개 · 4 계열

후보 B — 기준 모델 교체 규칙

기준 모델 (Flash-Next 학습 모델) 의 답은 네 조건을 모두 만족할 때만 보조 모델 쪽으로 바꿉니다 .

1 불일치

보조 모델이 기준과 다른 보기를 고름

2 확신 낮음

기준의 최고 확률 < CONF

3 마진 작음

기준의 1·2 위 확률 차 < MARGIN

4 합의

보조 AGREE 개 이상이 같은 다른 보기를 고름

채택 기준 (결과 전에 고정)

- 순이득 ⩾ +10
- 살린 문항 ⩾ 망친 문항 × 2
- 부트스트랩 1,000 번 중 95% 이상에서 이득
- 5 구역에서 고른 문턱값이 비슷함

문턱값은 5 겹 교차 적합으로 선택 · 기준 확률은 온도 보정 후 비교

실행	보조 모델	살림	망침	순이득	부트스트랩	판정
a12cf3	학습 4 + zero-shot 2	7	3	+4	88%	불채택
19f20f	학습 4 + zero-shot 1	6	4	+2	70%	불채택

최종 제출 두 번째 칸 : 505d49 (공개 0.97378)
기준 단독 (0.97110) 보다 9 문항 높음 . 후보 A 와 방식이 다른 파일로 둘째 칸을 채움 — 최종 점수는 두 제출 중 높은 쪽

제출 결과와 최종 제출

최종 제출은 후보 A 조합 ea0e9f 와 후보 B 교체 규칙 505d49 — 공개 점수는 확인용으로만 썼습니다 .

제출	방법	검증 %	공개 점수	공개 문항	최종
ea0e9f (후보 A)	**Gemma 4 bf16 · Gemma 4 OCR · InternVL3.5 · Qwen3.5 bf16 · Qwen3.8, 확률 평균**	**98.0**	**0.97736**	**3,281**	**제출**
505d49 (후보 B)	**Flash-Next 기준 + 보조 모델 표 (교체 규칙)**	**—**	**0.97378**	**3,269**	**제출**
b47d7c	ea0e9f 조합 + Flash-Next	97.6	0.97676	3,279	
majority_vote	초기 조합 3 개의 다수결	—	0.97676	3,279	
clean4_qg_hcx	Qwen3.5 · Qwen3.8 · Gemma 4 · Gemma 4 +dev · HCX(×2) 가중 평균	97.7	0.97646	3,278	
Flash-Next 단독	학습 모델 1 개 (후보 B 의 기준 모델)	96.9	0.97110	3,260	

! **공개 문항 수 = 점수 × 3,357**
상위 제출끼리는 2~3 문항 차이 — 공개 절반에서 약 20 문항이 갈려 , 운만으로 ±4~5 문항은 흔합니다 .

! **두 번째 칸은 방식이 다른 후보로**
최종 점수는 두 제출 중 높은 쪽입니다 . 검증으로 고른 조합에 , 방식이 다른 교체 규칙 파일을 더했습니다 .

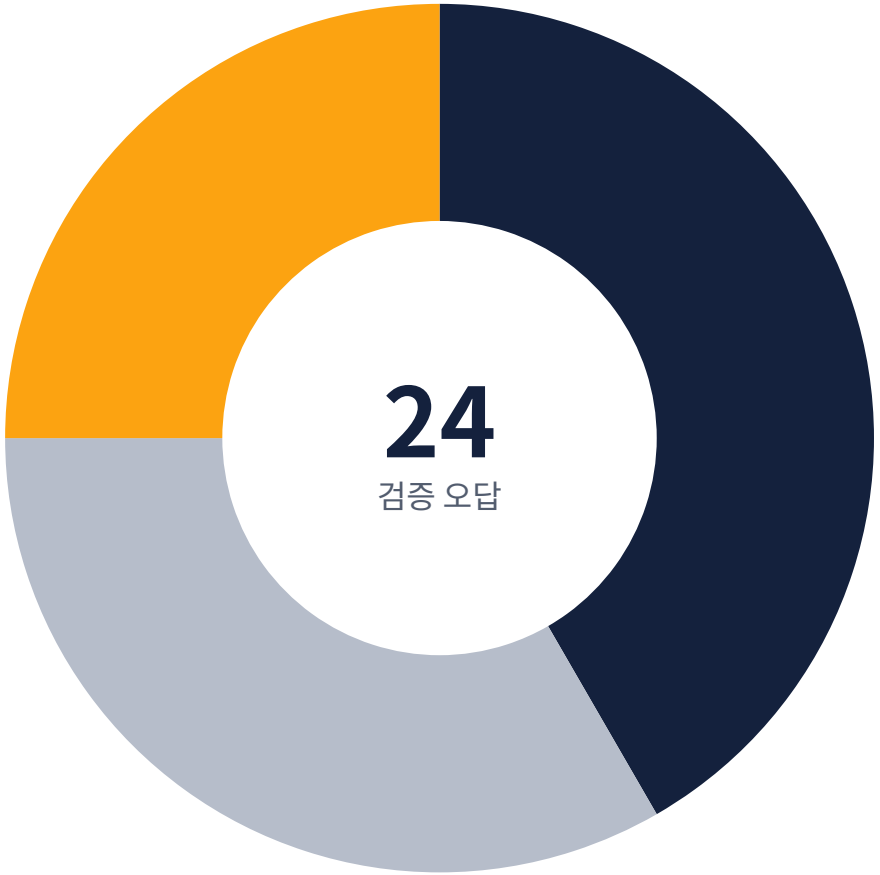
채택하지 않은 실험 — 단독 개선 ≠ 조합 개선

미리 정한 기준으로 판정 — 검증 순이득이 0 이하였거나 공개 점수가 떨어졌습니다 .

실험	결과	판단
학습 변형 19 가지 (LR · epoch · LoRA 세기 · 보조 손실)	단독 96.6~97.6%, 앙상블 순이득 – 2~0	불채택
bf16 재학습 (NF4 대비)	같은 시드면 답 99% 동일 (Qwen3.5 97.2 → 97.1)	병목 아님
학습 데이터 3,500 문항	5,714 문항과 같은 97.2%	데이터 양 충분
OCR 글자 프롬프트	Gemma 97.5 → 97.7 · Qwen3.5 97.1 → 96.9	일관된 이득 없음
보기 순열 TTA	공개 0.97557 · 0.97587 (원래보다 2~4 문항 낮음)	불채택
애매한 문항 고해상도 재채점 (3·4 배)	멤버 단위 이득 없음	불채택
보기별 예 / 아니오 검증	최고 조합 위에서 98.0 → 97.7	불채택
검증 포함 재학습 (_full) 으로 교체	공개 4 문항 하락	불채택
dev 의사 라벨 추가 학습	Gemma 97.6 → 97.4 · Qwen3.8 96.8 → 96.3	불채택

오답 분석 — 천장은 라벨이 정한다

검증 기반 조합의 오답 24 개를 이미지로 직접 확인하니 , 모델로 고칠 수 있는 건 6 개 남짓이었습니다 .



라벨 · 문제 오류 10

간판은 ROCK 인데 정답 POP · 브랜드 Johnnie Walker 인데 정답 Blue Label · 이미지에 없는 TANQUERAY

답이 둘 다 됨 8

札幌 = Sapporo · 48 만 / 40 만 · “ 밍기적” vs “ 망기적”

모델 실수 6

거꾸로 붙은 “냉장보관” 스티커 · 작은 글씨 100g · 출구 안내판 배치

학습 라벨은 원본 그대로 두었습니다 (test 에도 같은 성격의 문항이 있을 수 있음). 조합으로 고칠 여지는 멤버 의견이 갈리는 문항 몇 개뿐이었습니다 .

코드 구성과 실행 방법

노트북 번호 순서대로 실행 — 모든 결과는 vqa_runs/< 실행 >/ 에 예측 CSV 와 train_log.json 으로 남습니다 .

순서	노트북	환경	하는 일
0	**00_data_prep · 00b_ocr_paddle**	CPU · GPU	데이터 점검 , 고정 분할 확인 , 보조 학습 데이터 , OCR
1	**01_train_vlm**	Colab A100 80GB · G4 96GB	학습 모델 전부 (RECIPE = 실행 이름)
2	**02_runpod_flashnext_bf16**	RunPod B300	Qwen3.8-Flash-Next 학습
3	**03a_zs122b_vllm_colab · 03b_runpod_zs_any**	G4 · B300	학습 없는 대형 모델 채점 (vLLM)
4	**04_runpod_xcheck_any**	B300	판정 모델 (답이 갈린 문항만)
5	**05_ens_search · 06_anchor_rescue**	CPU	조합 · 교체 규칙 → 제출 CSV + 설정 JSON
6	**07_final_check**	CPU	고른 CSV 형식 점검 + 설정 JSON 만으로 다시 만들어 대조
—	**util_runpod_bridge_colab**	CPU	Drive ↔ HF 비공개 저장소 ↔ RunPod 파일 옮기기

README.md 실행 순서 · 환경 · 재현 방법 **MODEL_NOTES.md** 모델별 처리 (HCX 답 자리 고정 , 해상도 , Flash-Next 보정 , vLLM 설정)

재현성 — 세 단계로 확인

제출 CSV 는 저장된 예측과 설정 JSON 만으로 난수 없이 다시 만들어집니다 .

1 저장된 예측 → 제출 CSV

07_final_check 가 독립 코드로 다시 계산하고 멤버 예측 파일의 md5 를 대조

완전히 같음

→

2 저장된 어댑터 → 예측

01_train_vlm 에서 REUSE_FINISHED = True 로 검증 일부를 새로 채점해 저장된 예측과 비교

같은 GPU 면 답 ~100% 일치

→

3 처음부터 재학습

RUN_SUFFIX = "_repro" 로 같은 레시피를 다시 학습 (시드 · 순서 · 설정 동일)

GPU 비결정성으로 소수 문항 차이 가능

고정한 것

검증 분할 (시드 42 · md5) · 학습 시드 (문항 순서 · 보기 섞기 · LoRA 초기값) · 판정 모델 문항별 시드 · transformers 5.17.0(HCX 만 개발 커밋) · peft 0.21.0 · bitsandbytes 0.50.2 · vLLM 0.30.0

코드 점검

작은 모델 (CPU) 로 학습 노트북 9 개 경로를 끝까지 실행 : 점검 실행 · 본 학습 · 비전 LoRA · 이어학습 + 보조 · OCR · 기록 대조 · 전체 데이터 · dev 의사 라벨 · 중단 후 이어하기 (한 번에 학습한 결과와 동일)

한계와 배운 점

모델을 바꾸는 것보다 , 무엇이 진짜 개선인지 가려내는 절차가 더 중요했습니다 .

1 천장은 라벨이 정한다

검증 오답의 절반 이상이 라벨 오류 · 복수 정답이고 , 멤버 전부가 같은 오답을 확신했습니다 .

2 검증 1,000 문항은 작았다

±3 문항은 우연과 구별하기 어렵습니다 . 학습은 3,500 문항이면 충분해 , 검증을 더 크게 둘 수 있었습니다 .

3 같은 문항 비교 · 사전 규칙

고친 · 새로 틀린 문항으로 판정하고 기준을 먼저 정하니 , 단독으로만 좋아 보이는 변형을 걸러낼 수 있었습니다 .

4 최고값은 부풀려진다

조합 수십만 개 중 1 등은 중첩 CV 에서 약 0.5%p 낮았고 , 공개 최고를 고를 때도 같습니다 .

5 다양성이 이득을 만든다

조합에 들어간 건 단독 순위보다 틀리는 문항이 다른 모델 (InternVL · OCR 모델) 이었습니다 .

6 정밀도는 병목이 아니었다

같은 시드의 NF4·bf16 답이 99% 같았고 , 초대형 모델은 사전 양자화 체크포인트로 썼습니다 .